

Estimacion y Propiedades del Modelo Lineal

Econometria IAE

Ricardo Pasquini

Octubre 2023

Modelo Lineal

- ▶ Anteriormente introducimos al modelo lineal para caracterizar la relación entre la variable a explicar (\mathbf{y}) y el vector de variables explicativas (\mathbf{x}).

$$\mathbf{y} = \mathbf{x}'\beta + e$$

- ▶ Además introdujimos la existencia de una mejor proyección lineal, que era estimada a partir del método de OLS:

$$\hat{\beta} = \operatorname{argmin}_{\beta} \sum_i e_i^2 = \operatorname{argmin}_{\beta} \sum_i (y - \mathbf{x}'\beta)^2$$

Plan

- ▶ Predicción y Bondad de Ajuste
- ▶ *Varianza* de nuestro modelo lineal. Este concepto resultará crítico para la formulación de tests de hipótesis.

Predicción y Residuo estimado

- ▶ Predicción

$$\hat{\mathbf{y}} = \mathbf{x}'\hat{\boldsymbol{\beta}}$$

- ▶ Residuo estimado

$$\hat{\mathbf{e}} = \mathbf{y} - \hat{\mathbf{y}}$$

Bondad de Ajuste

1. Error Cuadrático Medio (M.S.E.)

$$\text{MSE} = \frac{1}{n} \sum_i \hat{e}_i^2$$

- Nota: Veremos que un estimador insesgado de $E[e^2] = \frac{1}{n-k} \sum_i \hat{e}_i^2$

Bondad de Ajuste

2. R^2

► Partiendo de la relación:

$$Y_i = \hat{Y}_i + e_i$$

* Se puede mostrar que se cumple:

$$\sum (Y_i - \bar{Y})^2 = \sum (\hat{Y}_i - \bar{Y})^2 + \sum e_i^2$$

* Es decir:

$$SCTotales = SCExplicado + SCResiduos$$

Bondad de Ajuste

Por lo tanto, una medida de bondad de ajuste es:

$$R^2 = \frac{SC_{\text{Explicado}}}{SC_{\text{Totales}}} = 1 - \frac{SC_{\text{Residuos}}}{SC_{\text{Totales}}}$$

Bondad de Ajuste

Por definición:

$$R^2 = 1 - \frac{\sum \hat{e}_i^2}{\sum (y_i - \bar{y}_i)^2}$$

Pero cuando incluimos muchas variables esta medida pierde sentido.

Bondad de Ajuste R^2 ajustado

La arreglamos ajustando por grados de libertad:

$$\bar{R}^2 = 1 - \frac{\sum \hat{e}_i^2 / (n - k)}{\sum (y_i - \bar{y}_i)^2 / (n - 1)}$$

Modelo Lineal

- ▶ Anteriormente vimos que la mejor proyección lineal (en la población) es:

$$\beta = (E(xx')^{-1})E(xy)$$

- ▶ Podemos derivar el estimador OLS reemplazando por los estimadores de los valores esperados respectivos

$$\hat{\beta} = ((\frac{\sum x_i x_i'}{n})^{-1})(\frac{\sum x_i y_i}{n}) = (\sum x_i x_i')^{-1}(\sum x_i y_i)$$

- ▶ Este método se conoce como *plug-in*.
- ▶ Lo que hicimos fue estimar una función de la media poblacional $g(\mu)$ usando la media de la funciones $g(\hat{\mu}) = \frac{\sum g(y_i)}{n}$, una extensión de la Ley Grandes Números.

El estimador de OLS es insesgado

- ▶ En promedio el estimador del OLS obtiene el valor de β correcto.

$$E[\hat{\beta}] = \beta$$

- ▶ La demostración usa las propiedades de la esperanza:

$$E[\hat{\beta}] = E[(X'X)^{-1}X'Y] = E[(X'X)^{-1}X'(X\beta + e)] = \beta + E[X'e] = \beta$$

- ▶ En general no todos los estimadores que encontrarán serán insesgados, y esta es una propiedad deseable.

Varianza poblacional

$$\text{var}(X) = E[(X - E[X])^2]$$

- ▶ **Ejemplo:** Habíamos visto que si x es el valor que surge de la tirada de un dado, entonces $E[x] = 3.5$
- ▶ Varianza de x :

$$\begin{aligned}\text{var}(x) &= E[(x - E[x])^2] = E[(x - 3.5)^2] = \\ &= \frac{1}{6}(1 - 3.5)^2 + \frac{1}{6}(2 - 3.5)^2 + \dots + \frac{1}{6}(6 - 3.5)^2 = 2.916\end{aligned}$$

Varianza de $\hat{\beta}$

- ▶ La varianza del estimador, en general, es

$$V_{\hat{\beta}} = \text{var}(\hat{\beta}|X) = (X'X)^{-1}(X'DX)(X'X)^{-1}$$

donde

- ▶ X es una matriz formada por las variables explicativas, y
- ▶ D es la matriz que tiene $E(e_i^2|x_i) = \sigma_i^2$ en la diagonal y $E(e_ie_j|X)$ fuera de la diagonal.
- ▶ Por el momento σ_i^2 es desconocida

Propiedades del Estimador de OLS

- Notar que si las observaciones son *independientes* y estamos en el caso de *homocedasticidad*

$$V_{\hat{\beta}} = \text{var}(\hat{\beta}|X) = (X'X)^{-1}\sigma^2$$

- Donde σ^2 es la varianza (asumida constante) del error. Por esta razón, en general reducir el error del modelo (lo no-explicado) ayudará a mejorar la precisión de la estimación de los coeficientes.

Homoscedasticidad vs Heteroscedasticidad




Figure 1: Analisis grafico

Varianza del error OLS

- ▶ La varianza del error es

$$\text{Var}(e|X) = E(ee'|X) \stackrel{\text{def}}{=} D$$

- ▶ Donde D es la matriz que tiene a $E(e_i^2|x_i) = \sigma_i^2$ en la diagonal, y $E[e_i e_j|X]=0$ fuera de la misma (debido a la independencia de las observaciones). También se puede denotar $D = \text{diag}(\sigma_1, \sigma_2, \dots, \sigma_n)$
- ▶ Para el caso homocedástico:

$$\text{Var}(e|X) = I_n \sigma^2$$

Varianza del estimador de OLS

- En general la varianza de $\hat{\beta}$ es

$$V_{\hat{\beta}} = \text{var}(\hat{\beta}|X) = (X'X)^{-1}(X'DX)(X'X)^{-1}$$

donde $D = E(\mathbf{e}\mathbf{e}'|X)$ o dicho de otra forma la matriz que tiene $E(e_i^2|x_i) = \sigma_i^2$ en la diagonal y $E(e_i e_j|X)$ fuera de la diagonal.

$$(X'DX) = \sum_i^n x_i x_i' \sigma_i^2$$

Estimador de la Varianza del Error

- Recordemos que la varianza del error es equivalente al valor esperado del error al cuadrado. Queremos estimar $E(e_i^2|x_i)$. También podemos usar el estimador de momentos:

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n \hat{e}_i^2$$

- Resulta que el estimador es sesgado cuando cuando tengo pocas observaciones. Intuitivamente, para estimar el error se deben estimar previamente otros k parámetros, por lo que se pierden grados de libertad. Se ajusta de la siguiente forma:

$$s^2 = \left(\frac{1}{n-k}\right) \sum_{i=1}^n \hat{e}_i^2$$

Estimación de $\text{Var}(\hat{\beta})$ (bajo homocedasticidad)

- ▶ Bajo homocedasticidad, la matriz de covarianza toma la forma

$$\text{Var}(\hat{\beta}) = (X'X)^{-1}\sigma^2$$

- ▶ Podemos utilizar el estimador insesgado de σ^2 : s^2

$$\hat{\text{Var}}(\hat{\beta}) = (X'X)^{-1}s^2$$

- ▶ Este suele ser el estimador de default en muchos programas, incluso en STATA. Sin embargo hay que recordar que solo aplica bajo homocedasticidad (osea, condiciones bastante excepcionales).

Estimación de $\text{Var}(\hat{\beta})$ (bajo heterocedasticidad)

- Bajo heterocedasticidad, la matriz de covarianza toma la forma

$$V_{\hat{\beta}} = \text{var}(\hat{\beta}|X) = (X'X)^{-1}(X'DX)(X'X)^{-1}$$

- O también

$$V_{\hat{\beta}} = \text{var}(\hat{\beta}|X) = (X'X)^{-1} \sum_i^n x_i x_i' e_i^2 (X'X)^{-1}$$

Estimación de $\text{Var}(\hat{\beta})$ (bajo heterocedasticidad)

- ▶ Es fácil mostrar que si conociéramos los errores (quod-non), podríamos construir directamente un estimador insesgado.
- ▶ Un estimador *factible* podría reemplazar los errores estimados que surgen de OLS, simplemente \hat{e}_i :

$$V_{\hat{\beta}}^{White} = (X'X)^{-1} \left(\sum_i^n x_i x_i' E(\hat{e}_i^2 | X) \right) (X'X)^{-1}$$

- ▶ El estimador de *White* es muy utilizado y es la opción “robust” en Stata.

Estimación de $\text{Var}(\hat{\beta})$ (bajo heterocedasticidad)

- ▶ Como sabíamos que el estimador de la varianza del error es sesgado, una variante podría ser ajustar este estimador multiplicando por $n/(n - k)$

Scaled-White

$$V_{\hat{\beta}}^{\text{Scaled-White}} = \frac{n}{n - k} (X'X)^{-1} \left(\sum_i^n x_i x_i' E(\hat{e}_i^2 | X) \right) (X'X)^{-1}$$

- ▶ Otras especificaciones usualmente utilizadas incorporan los principios de utilizar estimaciones del error mediante predicción (forecast error) , o residuos estandarizados. (Ver opciones hc2 y hc3 en Stata).

Mínimos Cuadrados Generalizados

- Consideremos ahora una situación donde los errores, en general, podrían ser heterocedásticos, o incluso estar correlacionados (i.e., no ser independientes).

$$y = X\beta + e$$

$$E(e|X) = 0$$

$$\text{Var}(e|X) = \Omega$$

Mínimos Cuadrados Generalizados

- ▶ Bajo estos supuestos se puede mostrar que las propiedades de OLS en este caso son

$$E(\hat{\beta}|X) = \beta$$
$$\text{Var}(\hat{\beta}|X) = (X'X)^{-1}(X'\Omega X)(X'X)^{-1}$$

- ▶ Usando el teorema de Gauss-Markov se puede ver que OLS es ineficiente, pues la varianza no es la mínima posible (que para este caso sería $(X'\Omega^{-1}X)^{-1}$)

Mínimos Cuadrados Generalizados

- ▶ Suponiendo que conocemos Ω en una cierta escala (i.e., suponemos que $\Omega = c^2 * \Sigma$ con Σ conocido.) Es posible derivar un estimador alternativo que logra la mínima varianza.
- ▶ El procedimiento consiste en premultiplicar el modelo por $\Sigma^{-1/2}$, y obtener:

$$\tilde{y} = \tilde{X}\beta + \tilde{e}$$

donde $\tilde{y} = \Sigma^{-1/2}y$, etc.

- ▶ Se puede mostrar fácilmente que esto resulta en:

$$\tilde{\beta}_{GLS} = (X'\Sigma^{-1/2}X)^{-1}(X'\Sigma^{-1/2}y)$$

- ▶ Este estimador redundante en la menor varianza, pero como no conocemos Σ , no es factible. Pero en la práctica se utilizan varias formas de aproximar Σ .

Test de Hipótesis

- ▶ Un test de hipótesis de especial interés será convalidar si (en la población) $\beta_j = 0$.
- ▶ Lo formalizamos con el test

$$H_0 : \beta_j = 0$$

$$H_1 : \beta_j \neq 0$$

- ▶ Podemos testearlo con:

$$t = \frac{b_j}{\text{std.error}(\beta)} = \frac{b_j}{\sqrt{\hat{\text{Var}}(\beta)}} \sim T_{n-k-1}$$

Modelo de Regresión *Normal*

- Incorporando el supuesto de que los errores se distribuyen normalmente

$$\frac{\hat{\beta}_j - \beta_j}{s(\hat{\beta}_j)} = \frac{\hat{\beta}_j - \beta_j}{s \sqrt{[(X'X)^{-1}]_{jj}}} \sim \frac{N\left(0, \sigma^2 [(X'X)^{-1}]_{jj}\right)}{\sqrt{\frac{\sigma^2}{n-k} \chi_{n-k}^2} \sqrt{[(X'X)^{-1}]_{jj}}} = \frac{N(0, 1)}{\sqrt{\frac{\chi_{n-k}^2}{n-k}}} \sim t_{n-k}$$

a t distribution with $n - k$ degrees of freedom.

Figure 2: Test

Distribución T

Density of the t -distribution (red) for 1, 2, 3, 5, 10, and 30 degrees of freedom compared to the standard normal distribution (blue).

Previous plots shown in green.




Figure 3: T-distribution

Conclusiones

- ▶ La variabilidad de los estimadores dependerá de las variables explicativas en el modelo pero también de la variabilidad del error: bajar el error del modelo reducirá la variabilidad de los $\hat{\beta}$.
- ▶ El análisis del error (y sus supuestos) es importante en cuanto de ello depende la elección de la estimación de varianza y del test estadístico asociado.
 - ▶ Homocedasticidad/Heterocedasticidad
 - ▶ Normalidad
 - ▶ Independencia

Referencias

- ▶ Hansen, B. 2018, Econometrics