

Econometria

Modelo de Regresión Lineal Simple

Pasquini, Ricardo

IAE Business School
Universidad Austral

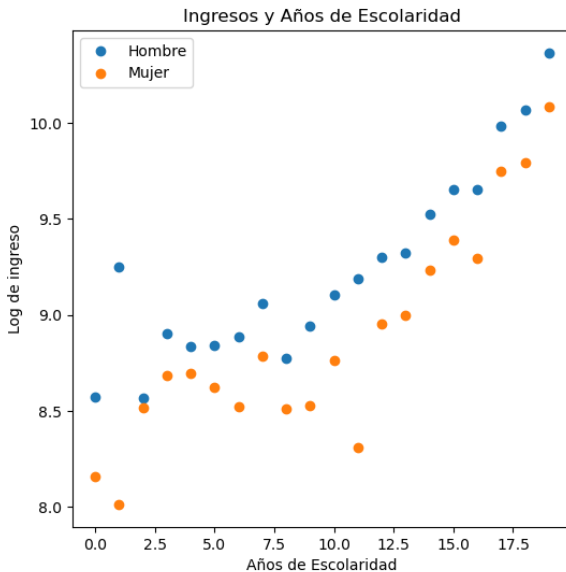
20 de agosto de 2025

Objetivos de Aprendizaje

- ▶ Definir un modelo de regresión con una variable explicativa.
- ▶ Comprender los componentes del modelo de regresión.
- ▶ Aprender a estimar el modelo de regresión.
- ▶ Interpretar los coeficientes de regresión.
- ▶ Evaluar la bondad de ajuste del modelo.

Motivación: Modelo CEF

Ejemplo: Ingresos v Años de Escolaridad



Modelo de regresión simple

$$\underbrace{Y_i}_{\substack{\text{Variable} \\ \text{a} \\ \text{explicar} \\ \text{o} \\ \text{Dependiente}}} = \underbrace{\beta_0}_{\substack{\text{Constante} \\ \text{o inter-} \\ \text{cepto}}} + \beta_1 \cdot \underbrace{X_i}_{\substack{\text{Variable} \\ \text{explicativa} \\ 1 \\ \text{(independiente)}}} + \underbrace{\varepsilon_i}_{\text{Error}}$$

- ▶ β_0, β_1 son los coeficientes a ser estimados.
- ▶ Una vez estimados los denotamos con $\hat{\beta}_0, \hat{\beta}_1$.
- ▶ $\hat{\beta}_0$ es el intercepto y $\hat{\beta}_1$ es la pendiente.

Estimador de Mínimos Cuadrados Ordinarios (OLS)

- ▶ El estimador OLS es utilizado para estimar los coeficientes de un modelo de regresión lineal.
- ▶ Minimiza la suma de los cuadrados de los residuos (RSS), que es la diferencia entre los valores observados de Y y los valores predichos por el modelo.

Estimador de Mínimos Cuadrados Ordinarios (OLS)

Paso 1: Definir la función de pérdida (RSS):

$$RSS = \sum_{i=1}^n (Y_i - \hat{Y}_i)^2$$

Paso 2: Minimizar la función de pérdida en términos de β_0 y β_1 .

$$\min_{\beta_0, \beta_1} RSS = \sum_{i=1}^n (Y_i - \beta_0 - \beta_1 X_i)^2$$

Paso 3: Resolver las ecuaciones resultantes para β_0 y β_1 .

Estimador de Mínimos Cuadrados Ordinarios (OLS)

Derivadas Parciales:

Derivamos la función de pérdida (RSS) respecto a β_0 y β_1 y las igualamos a cero para minimizar RSS:

$$\frac{\partial RSS}{\partial \beta_0} = -2 \sum_{i=1}^n (Y_i - \beta_0 - \beta_1 X_i) = 0$$

$$\frac{\partial RSS}{\partial \beta_1} = -2 \sum_{i=1}^n X_i (Y_i - \beta_0 - \beta_1 X_i) = 0$$

Estas ecuaciones conducen a las soluciones para $\hat{\beta}_0$ y $\hat{\beta}_1$.

Estimador de Mínimos Cuadrados Ordinarios (OLS)

Las ecuaciones resultantes para $\hat{\beta}_0$ y $\hat{\beta}_1$ son:

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sum_{i=1}^n (X_i - \bar{X})^2}$$

$$\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{X}$$

Donde \bar{X} y \bar{Y} son las medias muestrales de X y Y respectivamente.

Estos son los estimadores de mínimos cuadrados ordinarios (OLS) para el modelo de regresión lineal simple.

Estimadores de Mínimos Cuadrados Ordinarios (OLS)

Ejemplo: Ingresos y Años de Escolaridad

```
modelo=smf.ols(formula='logingreso ~ aesc',data=df2)
resultados=modelo.fit()
print(resultados.summary())
```

OLS Regression Results


Dep. Variable:	logingreso	R-squared:	0.207
Model:	OLS	Adj. R-squared:	0.207
Method:	Least Squares	F-statistic:	2366.
Date:	Wed, 20 Aug 2025	Prob (F-statistic):	0.00
Time:	17:59:52	Log-Likelihood:	-10880.
No. Observations:	9062	AIC:	2.176e+04
Df Residuals:	9060	BIC:	2.178e+04
Df Model:	1		
Covariance Type:	nonrobust		

	coef	std err	t	P> t	[0.025	0.975]
Intercept	9.9699	0.031	320.835	0.000	9.909	10.031
aesc	0.1104	0.002	48.639	0.000	0.106	0.115

Omnibus:	1489.077	Durbin-Watson:	1.822
Prob(Omnibus):	0.000	Jarque-Bera (JB):	3561.197
Skew:	-0.933	Prob(JB):	0.00
Kurtosis:	5.440	Cond. No.	50.6


Estimadores de Mínimos Cuadrados Ordinarios (OLS)

Ejemplo: Ingresos y Años de Escolaridad



Estimadores de Mínimos Cuadrados Ordinarios (OLS)

Ejemplo: Regresión y CEF



Bondad de Ajuste

- ▶ Medidas de bondad de ajuste: R^2 y MSE .

Bondad de Ajuste - R^2

- ▶ El coeficiente R^2 se define como la proporción de la varianza de la variable dependiente Y que es explicable por la variable X .
- ▶ Paso 1: Calcular los valores predichos de Y utilizando la ecuación de regresión:

$$\hat{Y}_i = \hat{\beta}_0 + \hat{\beta}_1 X_i$$

Donde \hat{Y}_i es el valor predicho de Y para la i -ésima observación, y $\hat{\beta}_0$ y $\hat{\beta}_1$ son los coeficientes estimados obtenidos del análisis de regresión.

- ▶ Paso 2: Calcular la suma total de cuadrados (TSS), que mide la variabilidad total en la variable dependiente:

$$TSS = \sum_{i=1}^n (Y_i - \bar{Y})^2$$

Bondad de Ajuste - R^2

- Paso 3: Calcular la suma de cuadrados residual (RSS), que mide la variabilidad que no es explicada por el modelo de regresión:

$$RSS = \sum_{i=1}^n (Y_i - \hat{Y}_i)^2$$

- Paso 4: Calcular la suma de cuadrados explicada (ESS), que mide la variabilidad explicada por el modelo de regresión:

$$ESS = \sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2$$

- Paso 5: Calcular R^2 utilizando la fórmula:

$$R^2 = \frac{ESS}{TSS} = 1 - \frac{RSS}{TSS}$$

Bondad de Ajuste - R^2

```
modelo=smf.ols(formula='ingtot_2 ~ aesc',data=df2)
resultados=modelo.fit()
print(resultados.summary())
```

OLS Regression Results

Dep. Variable:	ingtot_2	R-squared:	0.263
Model:	OLS	Adj. R-squared:	0.263
Method:	Least Squares	F-statistic:	4437.
Date:	Wed, 20 Aug 2025	Prob (F-statistic):	0.00
Time:	15:27:36	Log-Likelihood:	-1.6070e+05
No. Observations:	12432	AIC:	3.214e+05
Df Residuals:	12430	BIC:	3.214e+05
Df Model:	1		
Covariance Type:	nonrobust		

	coef	std err	t	P> t	[0.025	0.975]
Intercept	-3.578e+04	2150.736	-16.638	0.000	-4e+04	-3.16e+04
aesc	1.149e+04	172.493	66.608	0.000	1.12e+04	1.18e+04

Omnibus:	10130.562	Durbin-Watson:	1.837
Prob(Omnibus):	0.000	Jarque-Bera (JB):	559375.099
Skew:	3.527	Prob(JB):	0.00
Kurtosis:	35.095	Cond. No.	30.2

Error Cuadrático Medio (MSE)

- ▶ El MSE es una medida de la calidad de un modelo de regresión.
- ▶ Indica el promedio de los cuadrados de los errores, es decir, la diferencia entre los valores predichos por el modelo y los valores reales de la variable dependiente.

Error Cuadrático Medio (MSE)

Fórmula

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (Y_i - \hat{Y}_i)^2$$

- ▶ Donde Y_i es el valor real de la variable dependiente para la i -ésima observación.
- ▶ \hat{Y}_i es el valor predicho por el modelo de regresión para la i -ésima observación.
- ▶ n es el número total de observaciones.

Error Cuadrático Medio (MSE)

- **Paso 1:** Calcular los residuos para cada observación:

$$\hat{\varepsilon}_i = Y_i - \hat{Y}_i$$

- **Paso 2:** Elevar al cuadrado cada error:

$$\hat{\varepsilon}_i^2 = (Y_i - \hat{Y}_i)^2$$

- **Paso 3:** Calcular el promedio de los residuos al cuadrado:

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n \hat{\varepsilon}_i^2$$

Referencias

- ▶ Wooldridge ch. 2