

Econometria

Propiedades Estadísticas Modelo de Regresión Lineal Simple

Pasquini, Ricardo

IAE
Universidad Austral

27 de agosto de 2025

Modelo de regresión simple

Repaso: Estimadores OLS

$$\underbrace{Y_i}_{\substack{\text{Variable} \\ \text{a} \\ \text{explicar} \\ \text{o} \\ \text{Dependiente}}} = \underbrace{\beta_0}_{\substack{\text{Constante} \\ \text{o inter-} \\ \text{cepto}}} + \beta_1 \cdot \underbrace{X_i}_{\substack{\text{Variable} \\ \text{explicativa} \\ 1 \\ \text{(independiente)}}} + \underbrace{\varepsilon_i}_{\text{Error}}$$


- ▶ $\hat{\beta}_0, \hat{\beta}_1$ surgen de la minimización de la suma de los residuos al cuadrado (OLS).
- ▶ Los estimadores OLS son:

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sum_{i=1}^n (X_i - \bar{X})^2}$$

$$\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{X}$$


Estimadores de Mínimos Cuadrados Ordinarios (OLS)

Ejemplo: Ingresos y Años de Escolaridad



Estimadores de Mínimos Cuadrados Ordinarios (OLS)

Ejemplo: Regresión y CEF



Propiedades Estadísticas de los Coeficientes

Insesgadez

- ▶ **Ausencia de Sesgo (Insesgadez):** Esta propiedad establece que, *en valor esperado*, los coeficientes estimados serán iguales a los verdaderos coeficientes poblacionales.
- ▶ Formalmente, se define como:


$$E(\hat{\beta}_j) = \beta_j$$

- ▶ Intuición: Aunque las estimaciones individuales pueden variar debido a la aleatoriedad inherente del muestreo, si pudiéramos repetir esta estimación en múltiples muestras, el promedio de estas estimaciones coincidiría con el valor verdadero.



Propiedades Estadísticas de los Coeficientes

Insesgidez


Desviación Estándar del Error (σ_ε)



Desviación Estándar de X (σ_X)



Distribución de estimaciones de β_0 ?



Distribución de estimaciones de β_1 ?




Figura: Simulación. Ver en [SimuEcon.com](https://simucon.com)

Idea de la Simulación

- ▶ **Objetivo:** Mostrar que los coeficientes del modelo OLS son insesgados.
- ▶ **Pasos de la simulación:**
 - ▶ **Definición de parámetros:** Establecemos los valores verdaderos de los coeficientes asumidos verdaderos (β_0 y β_1), tamaño de muestra y número de simulaciones.
 - ▶ **Iteración:** Realizar múltiples simulaciones.
 - ▶ Generamos pares (x,y) provenientes de la población (cumplen $y = \beta_0 + \beta_1 X + \epsilon$)
 - ▶ Ajustamos el modelo de regresión lineal y obtenemos los estimadores de los coeficientes.
 - ▶ Almacenar los valores estimados de los coeficientes.
 - ▶ **Visualización:** Construimos histogramas de los valores estimados de los coeficientes.
 - ▶ **Estadísticas descriptivas:** Calculamos media y desviación estándar de los valores estimados de los coeficientes.

Supuestos de OLS para garantizar que no hay sesgo

Detalles Técnicos

- ▶ Supuestos necesarios para la ausencia de sesgo del estimador OLS:
 1. Linealidad en los parámetros (el modelo poblacional es $y = \beta_0 + \beta_1 X + \varepsilon$)
 2. Muestreo aleatorio (los valores (x_i, y_i) son variables aleatorias del modelo poblacional)
 3. La esperanza condicional del error es cero ($E(\varepsilon|X) = 0$). En este caso, garantizado por OLS.
- ▶ Demostración:
 - ▶ Queremos demostrar que $E(\hat{\beta}_1) = \beta_1$
 - ▶ Partimos de la definición de $\hat{\beta}_1 = \frac{\sum(x_i - \bar{x})\varepsilon_i}{SST_x}$
 - ▶ Utilizamos que los datos provienen de la población, por lo que $Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i$
 - ▶ Luego $E(\hat{\beta}_1|X) = E(\beta_1 + \frac{\sum(x_i - \bar{x})\varepsilon_i}{SST_x} | X)$
 - ▶ $E(\hat{\beta}_1|X) = \beta_1 + \frac{1}{SST_x} \sum(x_i - \bar{x})E(\varepsilon_i|X)$
 - ▶ Como $E(\varepsilon_i|X) = 0$ (supuesto 3), entonces $E(\hat{\beta}_1|X) = \beta_1$
 - ▶ Luego $E(\hat{\beta}_1) = \beta_1$

Propiedades Estadísticas de los Coeficientes

Varianza

- ▶ Aunque insesgadas, nuestras estimaciones siempre exhibirán cierto grado de **varianza**, que cuantifica la incertidumbre alrededor del coeficiente estimado.
- ▶ Formalmente, se define como:

$$Var(\hat{\beta}_j) = \frac{\sigma^2}{\sum_{i=1}^n (X_{ij} - \bar{X}_j)^2}$$

- ▶ σ^2 es la varianza de los residuos.
- ▶ $\sum_{i=1}^n (X_{ij} - \bar{X}_j)^2$ es la suma de los cuadrados de las desviaciones de la variable independiente X_j con respecto a su media.
- ▶ Con múltiples variables se incorporará un factor de corrección adicional que dependerá de la correlación entre las variables independientes. (próxima clase)

Propiedades Estadísticas de los Coeficientes

Varianza

- ▶ La teoría indica que la varianza de nuestras estimaciones está influenciada por dos factores clave:
 - ▶ **Error en el modelo:** La presencia de variación no explicada en la variable dependiente (Y) contribuye a la varianza de nuestras estimaciones. Este error puede atribuirse a factores no incluidos en el modelo o a la aleatoriedad inherente en los datos.
 - ▶ **Variabilidad de la variable independiente:** Una mayor dispersión en los valores de nuestra variable independiente (X) conduce a una menor varianza en nuestras estimaciones de coeficientes. Esto se debe a que un rango más amplio de valores de X proporciona más información para estimar la relación con Y .

Varianza del Estimador OLS - Derivación

- ▶ Para derivar este resultado partimos de $\hat{\beta}_1 = \beta_1 + \frac{\sum (x_i - \bar{x}) \varepsilon_i}{SST_x}$
- ▶ Luego $Var[\hat{\beta}_1|x] = \frac{1}{SST_x^2} \sum (x_i - \bar{x})^2 Var(\varepsilon_i)$

Propiedades Estadísticas de los Coeficientes

Distribución de probabilidad de los Coeficientes

- ▶ Bajo ciertos supuestos, los coeficientes siguen una distribución normal:

$$\hat{\beta} \sim N(\beta, \text{Var}(\beta))$$

- ▶ El valor estandarizado sigue una Normal Estándar:


$$Z = \frac{\hat{\beta} - \beta}{\sqrt{\text{Var}(\beta)}} \sim N(0, 1)$$

- ▶ En la práctica, usamos:

$$T = \frac{\hat{\beta} - \beta}{\sqrt{\hat{\text{Var}}(\beta)}} \sim T_{n-1}$$

Test de Hipótesis

Distribución T y Potencia ?



Nivel de Significancia (α)	Potencia (%)
$\alpha = 0.01$	62.50%
$\alpha = 0.05$	85.10%
$\alpha = 0.10$	91.40%

Figura: Distribución del estadístico T bajo H_0

Test de Hipótesis

- ▶ Test típico:

$$\begin{cases} H_0 : \beta = 0 \\ H_a : \beta \neq 0 \end{cases}$$

- ▶ Interpretación: Si H_0 es válida, X no tiene efecto sobre Y

- ▶ **Lógica del Test:**

1. Asumimos $\beta = 0$ (Hipótesis nula)
 2. Derivamos la distribución de probabilidad según esa hipótesis
 3. Observamos nuestra estimación $\hat{\beta}$ y construimos el estadístico de prueba \hat{T}
 4. Si \hat{T} es muy atípico, rechazamos H_0
- ▶ Cuán atípico es \hat{T} ? **P-valor:** Probabilidad de observar un valor tan extremo como \hat{T} bajo H_0

Test de Hipótesis

```

                                OLS Regression Results
=====
Dep. Variable:                  ingreso    R-squared:                  0.176
Model:                          OLS       Adj. R-squared:            0.176
Method:                        Least Squares  F-statistic:              1609.
Date:                          Wed, 27 Aug 2025  Prob (F-statistic):    4.94e-324
Time:                          11:57:44      Log-Likelihood:           -1.1779e+05
No. Observations:              9062         AIC:                     2.356e+05
Df Residuals:                  9060         BIC:                     2.356e+05
Df Model:                      1
Covariance Type:               HC0
=====

               coef      std err          z      P>|z|      [0.025      0.975]
-----
Intercept -4.489e+04   3867.026   -11.607    0.000   -5.25e+04   -3.73e+04
aesc       1.325e+04   330.296    40.115    0.000    1.26e+04    1.39e+04
=====
Omnibus:                 7371.512   Durbin-Watson:              1.790
Prob(Omnibus):            0.000   Jarque-Bera (JB):          361472.985
Skew:                    3.555   Prob(JB):                  0.00
Kurtosis:                33.113   Cond. No.                  50.6
=====
```

Notes:

[1] Standard Errors are heteroscedasticity robust (HC0)

Figura: Interpretación del P-valor. Ver en SimuEcon.com

Test de Hipótesis

Ejemplo Pay-for-Performance - Lazear 2000

VOL. 90 NO. 5

LAZEAR: PERFORMANCE PAY AND PRODUCTIVITY

1353

TABLE 3—REGRESSION RESULTS

Regression number	Dummy for PPP person-month observation	Tenure	Time since PPP	New regime	R ²	Description
1	0.368 (0.013)				0.04	Dummies for month and year included
2	0.197 (0.009)				0.73	Dummies for month and year; worker-specific dummies included (2,755 individual workers)
3	0.313 (0.014)	0.343 (0.017)	0.107 (0.024)		0.05	Dummies for month and year included
4	0.202 (0.009)	0.224 (0.058)	0.273 (0.018)		0.76	Dummies for month and year; worker-specific dummies included (2,755 individual workers)
5	0.309 (0.014)	0.424 (0.019)	0.130 (0.024)	0.243 (0.025)	0.06	Dummies for month and year included

Notes: Standard errors are reported in parentheses below the coefficients.

Dependent variable: In output-per-worker-per-day.

Number of observations: 29,837.

Figura: Lazear 2000

Takeaways

- ▶ Reducir el error del modelo ayuda a mejorar la precisión de los coeficientes individuales
- ▶ Buscar ampliar la varianza de las variables explicativas incrementa la precisión.
- ▶ El test de hipótesis se realiza bajo una distribución de probabilidades centrada en la hipótesis nula (típicamente de 0 efecto). La rechazamos si encontramos un valor atípicamente alto (bajo). El p-valor, es la medida de cuán atípico es el valor encontrado.

Takeaways

- ▶ Puesto que solo podemos testear usando el estadístico T , y este estadístico considera el efecto en relación a su standard error, la *significatividad estadística* solo habla de un concepto relativo: cuan grande o chico es un efecto en relación a la precisión con la que fue estimado.